

Econometría Avanzada

Contrafactuales y modelo causal de Rubin

Manuel Fernández

Sesión 2

Temas de la clase:

1. Causalidad en estudios observacionales
2. El modelo causal de Rubin
3. La “revolución de credibilidad” en econometría


Causalidad en estudios observacionales

Preguntas causales

- La mayoría de preguntas que nos interesan en economía son de tipo **causal**.
 1. ¿Cuál es el *efecto* de aumentar el impuesto de renta sobre la inversión?
 2. ¿Cuál es el *efecto* de incrementar el salario mínimo sobre la informalidad laboral?
 3. ¿Cuál es el *efecto* de leer los capítulos asignados en el programa sobre la nota final del curso?
- ¿Cómo podemos responder este tipo de preguntas?
- ¿Cómo **plantearlas formalmente**?

El caso del consumo de tabaco

- En las décadas de 1950 y 1960 hubo un debate intenso en EE.UU. sobre si el cigarrillo **causaba** cáncer de pulmón.



- No es viable hacer ensayos clínicos tradicionales $\implies$ no hay acceso a **evidencia experimental**.

- **Evidencia sugestiva:**

- En 1900, el número de cigarrillos consumidos per cápita al año ≈ 0 . En 1950 $\approx 3,500$ (≈ 10 por día).
- La tasa de mortalidad $\times 100.000$ habitantes asociada a cáncer de pulmón se multiplicó por 4 (de 5 a 20) en ese periodo.

- Pero...

- **La relación no es determinística:** hay personas que fuman y no les da cáncer de pulmón, y hay personas que no fuman y les da cáncer de pulmón.
- **Todo lo demás no se mantiene constante:** muchas cosas cambiaron entre 1900-1950.

¿Podemos hablar de causalidad?

Holland (1986)

*“The reaction of many statisticians when confronted with the possibility that their profession might contribute to a **discussion of causation** is immediately to **deny that there is any such possibility**. ‘That **correlation is not causation** is perhaps the first thing that must be said”.*


Factores de confusión (*confounders*)

- **Problema:** es posible que *factores no observados* (e.g., un gen) (G), determinen conjuntamente el deseo de fumar (F) y el cáncer de pulmón (C).

(a) F causa C




(b) G causa F y C



- En el diagrama (b), la variable G es un factor de confusión: la **correlación es espuria**.

Parece que el cigarrillo sí causa cáncer

- En 1950, Richard Doll y Bradford Hill, dos **epidemiólogos**, publican los resultados de un estudio observacional.
 - Entrevistaron a pacientes con cáncer de pulmón: de 649 pacientes, **sólo dos reportaron que no habían sido fumadores.**
 - Estimaron que la probabilidad de que esta relación se debiera al azar (**correlación espuria**) era de **1.5 millones a 1.**
 - Otros investigadores replican estos resultados.




Richard Doll (1912–2005)

Que el comité decida

- Ante la epidemia de cáncer de pulmón, el gobierno de EE.UU. crea un comité para estudiar el tema en 1962.
 - 10 expertos: 5 fumadores y 5 no fumadores, con 2 personas sugeridas por la industria del tabaco.
- El reporte determina que la evidencia indica una **posible relación causal**.

Consumo de cigarrillo y prevalencia de cáncer de pulmón



Fuente: Pearl and Mackenzie (2020)

El modelo causal de Rubin

El problema del lenguaje

- Se necesita un **lenguaje** para pensar **formalmente** problemas de **causalidad** en el contexto de **estudios observacionales**.
- ¿Cómo podemos **plantear el problema** de una manera precisa?
- ¿Cómo podemos **medir los efectos de las causas**?

Preguntas causales y contrafactuales

- Para responder preguntas **causales**:
 1. ¿Cuál es el *efecto* de $\uparrow$ el impuesto de renta sobre la inversión?
 2. ¿Cuál es el *efecto* de $\uparrow$ el salario mínimo sobre la informalidad?
 3. ¿Cuál es el *efecto* de leer los capítulos sobre la nota final del curso?
- Necesitamos saber el **contrafactual**:
 1. ¿**Qué hubiera pasado** con la inversión si no aumenta el impuesto?
 2. ¿**Qué hubiera pasado** con la informalidad si no subía el salario mínimo?
 3. ¿**Qué hubiera pasado** con la nota si el estudiante no leía los capítulos?

The Road Not Taken, Robert Frost (1915)

- Un ejercicio de imaginación: pensar en “universos paralelos”.

Two roads diverged in a yellow wood,
And sorry I could not travel both
And be one traveler, long I stood
And looked down one as far as I could
To where it bent in the undergrowth;

Then took the other, as just as fair,
And having perhaps the better claim,
Because it was grassy and wanted wear;
Though as for that the passing there
Had worn them really about the same,

And both that morning equally lay
In leaves no step had trodden black.
Oh, I kept the first for another day!
Yet knowing how way leads on to way,
I doubted if I should ever come back.

I shall be telling this with a sigh
Somewhere ages and ages hence:
Two roads diverged in a wood, and I—
I took the one less traveled by,
And that has made all the difference.



Resultados potenciales (modelo causal de Rubin)

- Sea Y_i una variable de resultado **observada**, e.g., la nota de un estudiante i al final de semestre.
- Sea D_i una variable indicadora:

$$D_i = \begin{cases} 1 & \text{si } i \text{ lee la bibliografía} \\ 0 & \text{si } i \text{ no lee la bibliografía.} \end{cases}$$

- Dos **resultados potenciales**:

$$Y_i(D_i) = \begin{cases} Y_i(1) & \text{si } i \text{ lee la bibliografía} \\ Y_i(0) & \text{si } i \text{ no lee la bibliografía} \end{cases}.$$

El problema fundamental de la inferencia causal

- El **efecto causal** de leer la bibliografía para el estudiante i es la **diferencia de sus resultados potenciales**:

$$\tau_i \equiv Y_i(1) - Y_i(0).$$

- **Problema fundamental de la inferencia causal**: no podemos observar al mismo estudiante en ambos estados posibles. **Uno de los dos resultados es contrafactual**.

¿Qué observamos?

- Para un estudiante i , **lo que observamos** es:

$$Y_i = Y_i(1)D_i + Y_i(0)(1 - D_i).$$

Reorganizando,

$$\begin{aligned} Y_i &= Y_i(0) + \left(Y_i(1) - Y_i(0) \right) D_i \\ &= Y_i(0) + \tau_i D_i \end{aligned}$$

donde τ_i es el efecto causal.

El problema de identificación

- Suponga que tenemos una **muestra aleatoria** de la población de estudiantes: $\{(Y_i, D_i) : i = 1, \dots, N\}$.

i	D_i	$Y_i(1)$	$Y_i(0)$	Y_i
1	1	5,00	-	5,00
2	1	4,20	-	4,20
3	1	4,07	-	4,07
4	1	4,00	-	4,00
5	1	4,79	-	4,79
6	0	-	4,19	4,19
7	0	-	3,98	3,98
8	0	-	4,23	4,23
9	0	-	4,36	4,36
10	0	-	4,28	4,28
Promedio	0,5	4,41	4,21	4,31

Efecto promedio del tratamiento (ATE)

- Nunca observamos al mismo estudiante en los dos estados posibles, pero quizá podemos aprender algo si tenemos información sobre un grupo de estudiantes.
- Definamos el efecto causal promedio del tratamiento en la población (ATE) como:

$$\begin{aligned}\tau_{ATE} &\equiv \mathbb{E}[\tau_i] \\ &= \mathbb{E}[Y_i(1) - Y_i(0)] \\ &= \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)]\end{aligned}$$

- τ_{ATE} es el estimando: la cantidad o parámetro poblacional que queremos conocer.
- ¿Bajo qué condiciones podemos estimar τ_{ATE} ? Este es el problema de identificación.

Comparaciones ingenuas

- Considere comparar de manera “**ingenua**” la diferencia promedio de la nota entre los estudiantes que leen y los que no lo hacen.

$$\tau_{ING} = \underbrace{\mathbb{E}[Y_i | D_i = 1]}_{\text{Promedio dado que leen}} - \underbrace{\mathbb{E}[Y_i | D_i = 0]}_{\text{Promedio dado que no leen}}$$

- Dado que $Y_i = Y_i(1)$ si $D_i = 1$ y $Y_i = Y_i(0)$ si $D_i = 0$:

$$\tau_{ING} = \mathbb{E}[Y_i(1) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0].$$

- Un **estimador** “natural” usaría los promedios muestrales:

- $\bar{Y}(1) | D_i = 1 = 4,41$
- $\bar{Y}(0) | D_i = 0 = 4,21$

$\implies \hat{\tau}_{ING} = 4,41 - 4,21 = 0,20$, (o $\uparrow 4,75\%$ sobre la media del grupo de control).

El problema con las comparaciones ingenuas

- Preguntas:

1. ¿ $\tau_{ATE} = \tau_{ING}$?
2. ¿La media muestral es un buen estimador de la media poblacional?

- Desarrollemos un poco la expresión para τ_{ING} . Sumando y restando el **contrafactual**, $\mathbb{E}[Y_i(0)|D_i = 1]$,

$$\begin{aligned}\tau_{ING} &= \mathbb{E}[Y_i(1)|D_i = 1] - \mathbb{E}[Y_i(0)|D_i = 0] \\ &\quad + \left(\mathbb{E}[Y_i(0)|D_i = 1] - \mathbb{E}[Y_i(0)|D_i = 1] \right).\end{aligned}$$

Reorganizando

$$\tau_{ING} = \underbrace{\mathbb{E}[Y_i(1) - Y_i(0)|D_i = 1]}_{\text{¿Intuición?}} + \underbrace{\mathbb{E}[Y_i(0)|D_i = 1] - \mathbb{E}[Y_i(0)|D_i = 0]}_{\text{¿Intuición?}} \quad (1)$$

Definiciones: ATE, ATT y ATU

- *Average treatment effect (ATE)*

$$\tau_{ATE} \equiv \mathbb{E}[\underbrace{Y_i(1) - Y_i(0)}_{\equiv \tau_i}]. \quad (2)$$

- *Average treatment effect on the treated (ATT)*

$$\tau_{ATT} \equiv \mathbb{E}[\underbrace{Y_i(1) - Y_i(0)}_{\equiv \tau_i} | D_i = 1]. \quad (3)$$

- *Average treatment effect on the untreated (ATU)*

$$\tau_{ATU} \equiv \mathbb{E}[\underbrace{Y_i(1) - Y_i(0)}_{\equiv \tau_i} | D_i = 0]. \quad (4)$$

Comparaciones ingenuas, ATT y sesgo de selección

- Reemplazando la definición de **ATT** en (1),

$$\tau_{ING} = \tau_{ATT} + \underbrace{\mathbb{E}[Y_i(0)|D_i = 1] - \mathbb{E}[Y_i(0)|D_i = 0]}_{\text{Sesgo de selección}} \quad (5)$$

- La diferencia de medias ingenua combina dos efectos:
 - Efecto causal sobre los tratados (τ_{ATT}).
 - Sesgo de selección**.
- Si no hay **sesgo de selección**, podemos estimar τ_{ATT} con la comparación ingenua.
- Dado que no observamos $\mathbb{E}[Y_i(0)|D_i = 1]$, **no es posible determinar la magnitud del sesgo de selección** (ni su signo).

Sesgo de selección

- El **sesgo selección** es el principal **problema de identificación** al que nos enfrentamos en el trabajo empírico.
- En esencia, este problema radica en que si no tenemos cuidado vamos a terminar **comparando grupos que son diferentes de una forma sistemática y relevante** (peras vs. manzanas).
- Estrechamente ligado con la idea de **todo lo demás constante (o igual)** (*ceteris paribus*).
 - Comparamos las notas de los estudiantes que leen y los que no leen la bibliografía de la clase. **Todo lo demás constante** implica que lo único que los diferencia (en promedio) es haber leído.

El experimento ideal

- Para recuperar el efecto causal promedio sobre los tratados (ATT) necesitamos

$$\mathbb{E}[Y_i(0)|D_i = 1] = \mathbb{E}[Y_i(0)|D_i = 0]. \quad (6)$$

- Esto es análogo a encontrar un grupo de comparación (control) “adecuado”, en el sentido que **aproxima bien el contrafactual no observado**.
- **Experimento ideal:** suponga que los resultados potenciales son **independientes** de la asignación al tratamiento: $Y_i(0), Y_i(1) \perp\!\!\!\perp D_i$.
- En ese caso particular, no hay un **sesgo de selección** $\implies$

$$\mathbb{E}[Y_i(D_i)|D_i] = \mathbb{E}[Y_i(D_i)] \text{ para } D_i \in \{0, 1\}.$$

La “revolución de credibilidad” en econometría

La “revolución de credibilidad” en econometría

- Para responder muchas preguntas en Economía tenemos que recurrir a **estudios observacionales**.
- Antes de los 90s, el enfoque predominante era basar el trabajo econométrico en la modelación teórica (econometría estructural).
 - Modelar explícitamente el **proceso generador de los datos**.
 - Estimar los parámetros *primitivos* (preferencias y tecnología).

Leamer (1983)

“Hardly anyone takes data analysis seriously. Or perhaps more accurately, hardly anyone takes anyone else’s data analysis seriously”.

La “revolución de credibilidad” en econometría

- A partir de los 90s hay un movimiento hacia **técnicas experimentales y cuasi-experimentales**. Menor énfasis en la teoría.
- Parte importante de esta revolución fue el desarrollo de un **lenguaje** preciso para pensar en preguntas causales en trabajos empíricos.
- El objetivo de las diferentes **estrategias de identificación** es acercarse lo más posible al experimento ideal (**Angrist and Krueger, 1999**).
- Aun en **estudios observacionales** podemos estimar efectos causales en la medida que logremos construir **contrafactuales** válidos.

Premio Nobel 2021



III. Niklas Elmehed © Nobel Prize Outreach.

David Card

Prize share: 1/2



III. Niklas Elmehed © Nobel Prize Outreach.

Joshua D. Angrist

Prize share: 1/4



III. Niklas Elmehed © Nobel Prize Outreach.

Guido W. Imbens

Prize share: 1/4

- **David Card** “*for his empirical contributions to labour economics*”.
- **Joshua D. Angrist and Guido W. Imbens** “*for their methodological contributions to the analysis of causal relationships*”.