

Econometría Avanzada

Propiedades del Estimador de Mínimos Cuadrados Ordinarios (MCO)

Manuel Fernández

18 de agosto de 2025

Temas de la clase:

1. Propiedades asintóticas del estimador de MCO

- Consistencia
- Distribución asintótica
- Errores estándar del estimador de MCO

2. Anexos

- Insesgamiento
- Teorema de Gauss-Markov

Propiedades asintóticas del estimador de MCO

- **Teoría asintótica** (*en nuestro contexto*): tipos de **convergencia** de **secuencias de estimadores** cuando el tamaño muestral crece (*i.e.*, $N \rightarrow \infty$).
- ¿Por qué es importante?
 1. Permite establecer **propiedades deseables** de los estimadores en muestras grandes. ¿El estimador “mejora” a medida que aumenta el tamaño de la muestra?
 2. Facilita aproximar la **distribución de los estimadores**, lo que resulta esencial para la inferencia estadística (*e.g.*, pruebas de hipótesis, intervalos de confianza).

1. Propiedades asintóticas del estimador de MCO

- Consistencia
- Distribución asintótica
- Errores estándar del estimador de MCO

2. Anexos

Definición: Convergencia en probabilidad (débil)

Una secuencia de variables aleatorias $\{X_N : N = 1, 2, \dots\}$, **converge en probabilidad** a una **constante** c si, para todo $\epsilon > 0$,

$$\lim_{N \rightarrow \infty} \Pr[|X_N - c| > \epsilon] = 0.$$

- **Intuición:** La masa de probabilidad se concentra en c a medida que $N \rightarrow \infty$.
- **Notación:** $\text{plim } X_N = c$ o $X_N \xrightarrow{P} c$.
- **Nota:** La definición se extiende elemento por elemento a vectores y matrices aleatorias.

Definición: Consistencia de un estimador

Sea $\{\hat{\theta}_N : N = 1, 2, \dots\}$ una secuencia de estimadores del vector θ de $K \times 1$, donde N denota el tamaño de la muestra. Decimos que $\hat{\theta}_N$ es un **estimador consistente** de θ si

$$\hat{\theta}_N \xrightarrow{P} \theta.$$

- **Intuición:** A medida que aumenta el tamaño de la muestra, la probabilidad de que el estimador difiera del parámetro poblacional tiende a cero.
- **Nota:** Esta propiedad se evalúa independientemente de si el parámetro poblacional θ tiene o no una interpretación causal.

Teorema del mapeo continuo (Slutsky)

Sea $\mathbf{g} : \mathbb{R}^K \rightarrow \mathbb{R}^J$ una función continua. Sea $\{\hat{\boldsymbol{\theta}}_N : N = 1, 2, \dots\}$ una secuencia de vectores aleatorios de $K \times 1$ tal que $\hat{\boldsymbol{\theta}}_N \xrightarrow{P} \boldsymbol{\theta}$, entonces $\mathbf{g}(\hat{\boldsymbol{\theta}}_N) \xrightarrow{P} \mathbf{g}(\boldsymbol{\theta})$.

- **Intuición:** Las convergencias se preservan al aplicar funciones continuas, lineales y no lineales:

$$\text{plim } \mathbf{g}(\hat{\boldsymbol{\theta}}_N) = \mathbf{g}(\text{plim } \hat{\boldsymbol{\theta}}_N) = \mathbf{g}(\boldsymbol{\theta}).$$

- **Ejemplo.** Suponga que $\hat{\theta}_N \xrightarrow{P} \theta \in \mathbb{R}^+$, y que estamos interesados en $\text{plim } \exp(\hat{\theta}_N)$:

$$\text{plim } \exp(\hat{\theta}_N) = \exp(\text{plim } \hat{\theta}_N) = \exp(\theta).$$

Ley débil de los grandes números (WLLN)


Sea $\{\mathbf{X}_i : i = 1, 2, \dots, N\}$ una secuencia de vectores aleatorios de $K \times 1$ que son independientes e idénticamente distribuidos (i.i.d.) tal que $\mathbb{E}\|\mathbf{X}_i\| < \infty$. Entonces, se cumple la **ley débil de los grandes números**:

$$\bar{\mathbf{x}}_N = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \xrightarrow{p} \mathbb{E}[\mathbf{X}_i].$$

- **Intuición:** La media muestral converge a la media poblacional cuando $N \rightarrow \infty$.
- **Nota:** Existen versiones más generales del teorema que relajan el supuesto de i.i.d.

Ejemplo de la ley débil de los grandes números

- Queremos estimar la **favorabilidad promedio** de un candidato antes de una elección. Seleccionamos una muestra aleatoria de N individuos y les preguntamos si apoyan al candidato ($Y_i \in \{0, 1\}$).



Consistencia del estimador de MCO

- Modelo lineal (proyección poblacional):

$$Y_i = \mathbf{X}_i' \boldsymbol{\beta} + e_i, \quad \text{donde} \quad \boldsymbol{\beta} = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i']^{-1} \mathbb{E}[\mathbf{X}_i Y_i] \quad (1)$$

- Con una muestra aleatoria $\{(Y_i, \mathbf{X}_i) : i = 1, \dots, N\}$, el estimador de MCO es:

$$\hat{\boldsymbol{\beta}}_{mco} = \left(\frac{1}{N} \sum_i \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\frac{1}{N} \sum_i \mathbf{x}_i Y_i \right). \quad (2)$$

- Probabilidad límite:

$$\begin{aligned} \text{plim } \hat{\boldsymbol{\beta}}_{mco} &= \text{plim} \left(\left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i Y_i \right) \right) \\ &= \text{plim} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \text{plim} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i Y_i \right) \quad (\text{Slutsky}) \end{aligned}$$

Consistencia del estimador de MCO II

- Primer término:

$$\begin{aligned}\text{plim} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} &= \left(\text{plim} \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} && \text{(Slutsky)} \\ &= \mathbb{E} [\mathbf{x}_i \mathbf{x}_i']^{-1} && \text{(WLLN)}\end{aligned}$$

- Segundo término:

$$\text{plim} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i Y_i \right) = \mathbb{E} [\mathbf{x}_i Y_i] \quad \text{(WLLN)}$$

- Combinando:

$$\text{plim} \hat{\beta}_{mco} = \mathbb{E}[\mathbf{x}_i \mathbf{x}_i']^{-1} \mathbb{E}[\mathbf{x}_i Y_i] = \beta$$

1. Propiedades asintóticas del estimador de MCO

- Consistencia
- Distribución asintótica
- Errores estándar del estimador de MCO

2. Anexos

Definición: Convergencia en distribución

Una secuencia de variables aleatorias $\{X_N : N = 1, 2, \dots\}$ **converge en distribución** a una **variable aleatoria** Z si, para todo $x \in \mathbb{R}$ en los puntos de continuidad de la CDF de Z ,

$$\lim_{N \rightarrow \infty} \mathbf{F}_N(x) = \mathbf{G}(x),$$

donde

$$\mathbf{F}_N(x) = \Pr[X_N \leq x] \quad \text{es la CDF de } X_N,$$

y

$$\mathbf{G}(x) = \Pr[Z \leq x] \quad \text{es la CDF de } Z.$$

- **Notación:** $X_N \xrightarrow{d} Z$ (distribución límite).

- **Vectores:** La convergencia marginal de $\mathbf{X}_N$ **no implica** convergencia conjunta; la **dependencia** entre componentes importa.

Definición: Convergencia en distribución (vectores)

Una secuencia de **vectores aleatorios** $\{\mathbf{X}_N : N = 1, 2, \dots\}$, con dimensión $K \times 1$, **converge en distribución** a un vector aleatorio $\mathbf{Z} \in \mathbb{R}^K$ si, para todo vector determinístico $\mathbf{c} \in \mathbb{R}^K$,

$$\mathbf{c}'\mathbf{X}_N \xrightarrow{d} \mathbf{c}'\mathbf{Z}.$$

- **Intuición:** toda combinación lineal de $\mathbf{X}_N$ converge en distribución a la combinación lineal correspondiente de $\mathbf{Z}$.

Teorema del mapeo continuo (convergencia en distribución)

Sea $\{\hat{\theta}_N : N = 1, 2, \dots\}$ una secuencia de vectores aleatorios de dimensión $K \times 1$ tal que

$$\hat{\theta}_N \xrightarrow{d} \mathbf{Z}.$$

Si $\mathbf{g} : \mathbb{R}^K \rightarrow \mathbb{R}^J$ es una función continua, entonces

$$\mathbf{g}(\hat{\theta}_N) \xrightarrow{d} \mathbf{g}(\mathbf{Z}).$$

- **Intuición:** Si conocemos la distribución límite de $\hat{\theta}_N$, también conocemos la distribución límite de cualquier función continua de $\hat{\theta}_N$.

Teorema del límite central (CLT) – Lindeberg–Levy

Sea $\{\mathbf{X}_i : i = 1, 2, \dots, N\}$ una secuencia de vectores aleatorios de dimensión $K \times 1$, independientes e idénticamente distribuidos (i.i.d.), con media finita $\mathbb{E}[\mathbf{X}_i] = \mu$ y matriz de covarianza finita $\Sigma = \mathbb{E}[(\mathbf{X}_i - \mu)(\mathbf{X}_i - \mu)']$. Entonces,

$$\sqrt{N}(\bar{\mathbf{X}}_N - \mu) \xrightarrow{d} \mathcal{N}(0, \Sigma),$$

donde $\bar{\mathbf{X}}_N = \frac{1}{N} \sum_{i=1}^N \mathbf{X}_i$.

- **Nota:** Existen versiones más generales del teorema que relajan el supuesto de i.i.d. (e.g., dependencia débil, heterogeneidad limitada).
- No se asume normalidad de $\mathbf{X}_i$; la normalidad emerge en el promedio.
- Un estimador tiene una **tasa de convergencia** a raíz- N si el error estándar del estimador disminuye proporcionalmente a $1/\sqrt{N}$.

Simulación del teorema del límite central

- **Distribuciones consideradas:**

- i. $f(x) = \lambda \exp(-\lambda x)$, con $\lambda = 1$ (Exponencial)

- ii. $f(x) = 1/(b - a)$, con $a = 0, b = 1$ (Uniforme)

- iii. $X \sim \text{Bernoulli}(p)$, con $p = 0,5$ (Bernoulli)

- **Algoritmo (repetido 10,000 veces):**


1. Extraer una muestra i.i.d. de tamaño $N = 10^5$ de cada distribución.
2. Calcular el promedio muestral $\bar{\mathbf{X}}_N$.
3. Estandarizar:

$$\mathbf{Z}_N = \frac{\sqrt{N}(\bar{\mathbf{X}}_N - \mu)}{\sigma}.$$


4. Guardar $\bar{\mathbf{X}}_N$ y $\mathbf{Z}_N$ para cada muestra y distribución.

Resultados simulación: distribución de Z_N


(a) Exponencial



(b) Uniforme




(c) Binomial



Convergencia en distribución y convergencia en probabilidad

- Queremos estimar la **favorabilidad promedio** de un candidato antes de una elección. Seleccionamos una muestra aleatoria de N individuos y les preguntamos si apoyan al candidato ($Y_i \in \{0, 1\}$).



Distribución asintótica del estimador de MCO

- Muestra aleatoria: $\{(Y_i, \mathbf{X}_i) : i = 1, \dots, N\}$.

$$\hat{\beta}_{mco} = \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i Y_i \right).$$

- Sustituyendo $Y_i = \mathbf{X}_i' \beta + e_i$:

$$\hat{\beta}_{mco} = \beta + \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i e_i \right).$$

- Reorganizando y multiplicando por $\sqrt{N}$:

$$\sqrt{N} (\hat{\beta}_{mco} - \beta) = \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \underbrace{\left(\frac{1}{\sqrt{N}} \sum_{i=1}^N \mathbf{x}_i e_i \right)}_{\text{término estocástico}}.$$

Distribución del término estocástico

- Definamos $\mathbf{W}_i \equiv \mathbf{X}_i e_i$ y su promedio muestral $\bar{\mathbf{W}}_N = \frac{1}{N} \sum_{i=1}^N \mathbf{W}_i$.
- Por la [ley de los grandes números](#):

$$\text{plim } \bar{\mathbf{W}}_N = \mathbb{E}[\mathbf{W}_i] = \mathbb{E}[\mathbf{X}_i e_i] = 0.$$

- Consideremos la suma: $\frac{1}{\sqrt{N}} \sum_{i=1}^N \mathbf{W}_i = \sqrt{N} \bar{\mathbf{W}}_N$.
- Por el [teorema del límite central \(CLT\)](#):

$$\sqrt{N} \bar{\mathbf{W}}_N \xrightarrow{d} \mathcal{N}(0, \Sigma),$$

$$\text{donde } \Sigma = \mathbb{E}[\mathbf{W}_i \mathbf{W}_i'] = \mathbb{E} \left[(\mathbf{X}_i e_i)(\mathbf{X}_i e_i)' \right] = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i' e_i^2].$$

Teorema de Slutsky (corolario)

Si

$$\sqrt{N} \bar{\mathbf{W}}_N \xrightarrow{d} \mathcal{N}(0, \Sigma),$$

y

$$\mathbf{A}_N \xrightarrow{p} \mathbf{A},$$

entonces

$$\mathbf{A}_N \sqrt{N} \bar{\mathbf{W}}_N \xrightarrow{d} \mathcal{N}(0, \mathbf{A} \Sigma \mathbf{A}').$$

- En nuestro caso particular:

$$\mathbf{A}_N \equiv \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \xrightarrow{p} \mathbb{E} [\mathbf{x}_i \mathbf{x}_i']^{-1} \equiv \mathbf{A}. \quad (\text{WLLN})$$

Distribución límite de $\sqrt{N}(\hat{\beta}_{mco} - \beta)$

- En resumen, hemos mostrado que:

$$\sqrt{N}(\hat{\beta}_{mco} - \beta) = \mathbf{A}_N \sqrt{N} \bar{\mathbf{W}}_N \xrightarrow{d} \mathcal{N}(0, \mathbf{A} \Sigma \mathbf{A}') \quad (3)$$

donde:

- $\mathbf{A} = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i']^{-1}$,
 - $\Sigma = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i' e_i^2]$.
- Por lo tanto, la **matriz de varianza-covarianza** de $K \times K$ es

$$\mathbf{A} \Sigma \mathbf{A}' = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i']^{-1} \mathbb{E}[\mathbf{X}_i \mathbf{X}_i' e_i^2] \mathbb{E}[\mathbf{X}_i \mathbf{X}_i']^{-1}. \quad (4)$$

Los errores estándar teóricos utilizados para construir los estadísticos de prueba son las raíces cuadradas de los elementos diagonales de la ecuación (4)

Distribución asintótica del estimador de MCO

- Para obtener la distribución del estimador, dividimos por $\sqrt{N}$ y sumamos β .

$$\hat{\beta}_{mco} \stackrel{a}{\sim} \mathcal{N}(\beta, \frac{1}{N} \mathbf{A} \Sigma \mathbf{A}').$$

La llamamos **distribución asintótica**. Esta es una **aproximación para muestras finitas pero “suficientemente” grandes**.

- Recordar que $\hat{\beta}_{mco} \xrightarrow{P} \beta$, y el parámetro β no es estocástico, así que la distribución límite de $\hat{\beta}_{mco}$ es degenerada.

1. Propiedades asintóticas del estimador de MCO

- Consistencia
- Distribución asintótica
- Errores estándar del estimador de MCO

2. Anexos

Estimadores de la matriz de varianza–covarianza ($\mathbf{A}\Sigma\mathbf{A}'$)

- La matriz de varianza–covarianza depende de momentos poblacionales que en la práctica debemos **estimar**.
- La elección del estimador depende de los **supuestos** que hagamos sobre el término de error e_i en el modelo.
- Tres casos frecuentes en econometría aplicada:
 1. **Homoscedasticidad y no autocorrelación**: Supuesto clásico de MCO, pero **MUY** restrictivo.
 2. **Heteroscedasticidad y no autocorrelación**: Errores estándar *robustos* de White.
 3. **Heteroscedasticidad con autocorrelación en grupos**: Errores estándar agrupados o *clustered*.
- En cada caso, usamos los residuos estimados: $\hat{e}_i = Y_i - \mathbf{X}_i' \hat{\beta}_{mco}$

Homoscedasticidad y no autocorrelación

- **Supuestos:**

$$\text{Var}(e_i | \mathbf{X}) = \mathbb{E}[e_i^2 | \mathbf{X}] = \sigma^2 \quad \forall i, \quad \text{y} \quad \mathbb{E}[e_i e_j | \mathbf{X}] = 0 \quad \text{para } i \neq j.$$

- En este caso,

$$\begin{aligned} \mathbf{A}\Sigma\mathbf{A}' &= \mathbb{E}[\mathbf{X}_i\mathbf{X}_i']^{-1} \mathbb{E} \left[\mathbf{X}_i\mathbf{X}_i' \mathbb{E}[e_i^2 | \mathbf{X}_i] \right] \mathbb{E}[\mathbf{X}_i\mathbf{X}_i']^{-1} \quad (\text{LEI}) \\ &= \sigma^2 \mathbb{E}[\mathbf{X}_i\mathbf{X}_i']^{-1} \end{aligned}$$

- Si definimos $\hat{\sigma}^2 = \frac{\sum_i \hat{e}_i^2}{N-K}$, se puede que

$$\text{plim } \hat{\sigma}^2 = \sigma^2.$$

Así, se cumple:

$$\text{plim } \hat{\sigma}^2 \left(\frac{1}{N} \sum_{i=1}^N \mathbf{X}_i\mathbf{X}_i' \right)^{-1} = \mathbf{A}\Sigma\mathbf{A}'.$$

Heteroscedasticidad y no autocorrelación

- **Supuestos:**

$$\text{Var}(e_i | \mathbf{X}) = \mathbb{E}[e_i^2 | \mathbf{X}] = \sigma_i^2, \quad \text{y} \quad \mathbb{E}[e_i e_j | \mathbf{X}] = 0 \quad \text{para } i \neq j.$$

- **White (1980)** demuestra que

$$\text{plim} \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \hat{e}_i^2 = \mathbb{E}[\mathbf{x}_i \mathbf{x}_i' e_i^2].$$

Por consiguiente, se cumple:

$$\text{plim} \left(\left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \hat{e}_i^2 \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \right) = \mathbf{A} \Sigma \mathbf{A}'$$

Heteroscedasticidad con autocorrelación en grupos

- Dividimos las N observaciones en grupos $g \in \{1, \dots, G\}$.

- Supuestos:**

$$\text{Var}(e_{gi} \mid \mathbf{x}) = \sigma_{gi}^2, \quad \mathbb{E}[e_{gi}e_{gj} \mid \mathbf{x}] \neq 0 \text{ si } i \neq j, \quad \mathbb{E}[e_{gi}e_{hj} \mid \mathbf{x}] = 0 \text{ si } g \neq h$$

Es decir, se permite **heteroscedasticidad y correlación arbitraria dentro de cada grupo**, pero independencia entre grupos.

- Si definimos:

$$\hat{\Sigma} \equiv \frac{1}{N} \sum_{g=1}^G \left(\sum_{i \in g} \mathbf{x}_{gi} \hat{e}_{gi} \right) \left(\sum_{i \in g} \mathbf{x}_{gi} \hat{e}_{gi} \right)',$$

se cumple:

$$\text{plim} \left(\left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \hat{\Sigma} \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \right) = \mathbf{A} \Sigma \mathbf{A}'.$$

- La distribución asintótica del estimador MCO es:

$$\hat{\beta}_{mco} \stackrel{a}{\sim} \mathcal{N}\left(\beta, \frac{1}{N} \mathbf{A} \Sigma \mathbf{A}'\right),$$

donde $\mathbf{A} \Sigma \mathbf{A}'$ es la matriz de varianza-covarianza que debemos estimar.

- Según los supuestos sobre el término de error, obtenemos distintos estimadores consistentes:

$$\text{plim } \mathbf{A}_N \hat{\Sigma} \mathbf{A}_N' = \mathbf{A} \Sigma \mathbf{A}',$$

donde $\mathbf{A}_N$ es un estimador consistente de $\mathbf{A}$ y $\hat{\Sigma}$ es un estimador consistente de Σ .

- Los errores estándar para construir los estadísticos de prueba son las raíces cuadradas de los elementos diagonales.

Anexos

1. Propiedades asintóticas del estimador de MCO

2. Anexos

- Insesgamiento
- Teorema de Gauss-Markov

- Consideraremos dos propiedades de los estimadores en **muestras finitas**:
 1. **Insesgamiento**: Un estimador $\hat{\theta}$ del parámetro θ es insesgado si $\mathbb{E}[\hat{\theta}] = \theta$.
 2. **Eficiencia**: Sean $\hat{\theta}$ y $\tilde{\theta}$ dos estimadores insesgados del parámetro θ . Decimos que $\hat{\theta}$ es más eficiente que $\tilde{\theta}$ si $\text{Var}[\hat{\theta}] < \text{Var}[\tilde{\theta}]$.

Insesgamiento del estimador de MCO I

- Modelo lineal (proyección poblacional):

$$Y_i = \mathbf{X}_i' \boldsymbol{\beta} + e_i, \quad \text{donde} \quad \boldsymbol{\beta} = \mathbb{E}[\mathbf{X}_i \mathbf{X}_i']^{-1} \mathbb{E}[\mathbf{X}_i Y_i] \quad (5)$$

- Para demostrar **insesgamiento** y **eficiencia**, necesitamos un supuesto más fuerte: $\mathbb{E}[e_i | \mathbf{X}_i] = 0$ (i.e., la CEF es lineal)
- Con una muestra aleatoria $\{(Y_i, \mathbf{X}_i) : i = 1, \dots, N\}$, el estimador de MCO es:

$$\hat{\boldsymbol{\beta}}_{mco} = \left(\sum_i \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\sum_i \mathbf{x}_i Y_i \right). \quad (6)$$

Sustituyendo (5) en (6):

$$\hat{\boldsymbol{\beta}}_{mco} = \boldsymbol{\beta} + \left(\sum_i \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\sum_i \mathbf{x}_i e_i \right)$$

Insesgamiento del estimador de MCO II

- Tomando el **valor esperado condicional en la muestra $\mathbf{X}$** :

$$\begin{aligned}\mathbb{E}[\hat{\beta}_{mco}|\mathbf{X}] &= \beta + \mathbb{E}\left[\left(\sum_i \mathbf{x}_i \mathbf{x}_i'\right)^{-1} \left(\sum_i \mathbf{x}_i e_i\right) \mid \mathbf{X}\right] \\ &= \beta + \left(\sum_i \mathbf{x}_i \mathbf{x}_i'\right)^{-1} \left(\sum_i \mathbf{x}_i \mathbb{E}[e_i \mid \mathbf{X}]\right) \\ &= \beta.\end{aligned}$$

- Usando la **ley de la esperanza iterada**:

$$\begin{aligned}\mathbb{E}[\hat{\beta}_{mco}] &= \mathbb{E}\left[\mathbb{E}[\hat{\beta}_{mco}|\mathbf{X}]\right] \\ &= \beta.\end{aligned}$$

$\implies$ El **estimador de MCO** es **insesgado**.

Ejemplo de inesgamiento en datos simulados

- **Modelo Poblacional:**

$$Y_i = \beta_0 + \beta_1 X_i + e_i$$

- **Supuestos:**

- i. $\beta_0 = 10, \beta_1 = 5$

- ii. $X_i \sim \mathcal{N}(8, 16), e_i \sim \mathcal{N}(0, 9), \Rightarrow \mathbb{E}[e_i | \mathbf{X}] = 0$

- **Algoritmo (se repite 10,000 veces):**


1. Generar una muestra aleatoria (iid) de tamaño $N = 100$ para X_i y e_i .
2. Calcular Y_i usando los parámetros del modelo poblacional.
3. Estimar los parámetros por MCO, dada la muestra:

$$\hat{\beta}_{mco} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}$$


4. Guardar los valores estimados de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Distribución de $\hat{\beta}_0$, $\hat{\beta}_1$ en las 10,000 simulaciones

(a) $\hat{\beta}_0$ (promedio = 10.00)




(b) $\hat{\beta}_1$ (promedio = 4.99)



- La distribución está centrada en el valor poblacional.

Consistencia e insesgamiento



1. Propiedades asintóticas del estimador de MCO

2. Anexos

- Insesgamiento
- Teorema de Gauss-Markov

Teorema de Gauss-Markov

Bajo los siguientes supuestos, el estimador MCO de β es el **mejor estimador lineal insesgado** (BLUE):

1. Linealidad del modelo: $Y_i = \mathbf{X}_i' \beta + e_i$.
2. Exogeneidad: $\mathbb{E}[e_i \mid \mathbf{X}] = 0$.
3. No multicolinealidad perfecta: $\mathbb{E}[\mathbf{X}_i \mathbf{X}_i']$ es invertible.
4. Homoscedasticidad: $\text{Var}(e_i \mid \mathbf{X}) = \sigma^2$.
5. No autocorrelación: $\mathbb{E}[e_i e_j \mid \mathbf{X}] = 0$ ($i \neq j$).

- **Intuición:** Entre todos los estimadores lineales insesgados, el de MCO tiene la varianza más baja; es decir, es el más eficiente.

Demostración del teorema de Gauss-Markov

- Estimador de MCO:

$$\hat{\beta}_{mco} = \mathbf{A}\mathbf{Y}; \quad \mathbb{E} [\hat{\beta}_{mco}|\mathbf{X}] = \beta; \quad \text{Var} [\hat{\beta}_{mco}|\mathbf{X}] = \sigma^2(\mathbf{X}'\mathbf{X})^{-1},$$

donde $\mathbf{A} \equiv (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

- Sea $\tilde{\beta}$ otro estimador de β tal que

$$\tilde{\beta} = \mathbf{B}\mathbf{Y}; \quad \mathbb{E} [\tilde{\beta}|\mathbf{X}] = \beta.$$

- $\mathbb{E} [\tilde{\beta}|\mathbf{X}] = \mathbb{E} [\mathbf{B}\mathbf{Y}|\mathbf{X}] = \mathbb{E} [\mathbf{B}\mathbf{X}\beta + \mathbf{B}\mathbf{e}|\mathbf{X}] = \beta \implies \mathbf{B}\mathbf{X} = \mathbb{I}_K.$
- $\text{Var}[\tilde{\beta}|\mathbf{X}] = \sigma^2\mathbf{B}\mathbf{B}'$ (mismo procedimiento estimador de MCO).

- Sea $\mathbf{C} \equiv \mathbf{B} - \mathbf{A}$. Notar que $\mathbf{C}\mathbf{X} = \mathbf{0}$ porque $\mathbf{A}\mathbf{X} = \mathbb{I}_K$.

Demostración del teorema de Gauss-Markov

- De (ii)

$$\begin{aligned} \text{Var}[\tilde{\beta}|\mathbf{X}] &= \sigma^2 ((\mathbf{C} + \mathbf{A})(\mathbf{C} + \mathbf{A})') \\ &= \sigma^2 (\mathbf{CC}' + \mathbf{CA}' + \mathbf{AC}' + \mathbf{AA}') \\ &= \sigma^2 (\mathbf{CC}' + \mathbf{AA}') \\ &= \sigma^2 (\mathbf{CC}') + \text{Var}[\hat{\beta}_{mco}|\mathbf{X}] \end{aligned}$$

- Pero la forma cuadrática $\mathbf{CC}'$ es una matriz definida no negativa. Se tiene que cumplir que

$$\text{Var}[\hat{\beta}_{mco}|\mathbf{X}] \leq \text{Var}[\tilde{\beta}|\mathbf{X}].$$

Demostración: estimador $\hat{\sigma}^2$ de σ^2 es consistente

- Sea $\mathbf{M} \equiv (\mathbb{I}_N - \mathbf{X}\mathbf{A})$, donde $\mathbf{A} \equiv (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ y $\mathbf{X}$ es una matriz de $N \times K$.
- Algunas propiedades útiles de $\mathbf{M}$:
 - i. $\hat{\mathbf{e}} = \mathbf{M}\mathbf{y}$ (“residual maker”).
 - ii. $\mathbf{M} = \mathbf{M}'$ (simétrica).
 - iii. $\mathbf{M} = \mathbf{M}^2$ (idempotente).
 - iv. $\mathbf{M}\mathbf{X} = \mathbf{0}$.
 - v. $\hat{\mathbf{e}} = \mathbf{M}\mathbf{e}$ (usando i y iv)
- $\hat{\mathbf{e}}'\hat{\mathbf{e}} = \mathbf{e}'\mathbf{M}\mathbf{e}$, así que nos interesa

$$\text{plim} \frac{\hat{\mathbf{e}}'\hat{\mathbf{e}}}{N - K} = \text{plim} \frac{\mathbf{e}'\mathbf{M}\mathbf{e}}{N - K}$$

Demostración: estimador $\hat{\sigma}^2$ de σ^2 es consistente

- Expandiendo $\mathbf{M}$ y multiplicando y dividiendo por N

$$\begin{aligned}\text{plim} \frac{\hat{\mathbf{e}}' \hat{\mathbf{e}}}{N-K} &= \text{plim} \frac{N}{N-K} \left(\frac{\mathbf{e}' (\mathbb{I}_N - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') \mathbf{e}}{N} \right) \\ &= \text{plim} \frac{N}{N-K} \left(\frac{\mathbf{e}'\mathbf{e}}{N} - \frac{\mathbf{e}'\mathbf{X}}{N} \left(\frac{\mathbf{X}'\mathbf{X}}{N} \right)^{-1} \frac{\mathbf{X}'\mathbf{e}}{N} \right).\end{aligned}$$

- Abusando de Slutsky

1. $\text{plim} \frac{N}{N-K} = 1$
2. $\text{plim} \frac{\mathbf{e}'\mathbf{e}}{N} = \text{plim} \frac{1}{N} \sum_i \mathbf{e}_i^2 = \mathbb{E}[\mathbf{e}_i^2] = \sigma^2$
3. $\text{plim} \frac{\mathbf{X}'\mathbf{e}}{N} = \text{plim} \frac{1}{N} \sum_i \mathbf{x}_i \mathbf{e}_i = \mathbb{E}[\mathbf{x}_i \mathbf{e}_i] = 0$
4. $\text{plim} \left(\frac{\mathbf{X}'\mathbf{X}}{N} \right)^{-1} = \text{plim} \left(\frac{1}{N} \sum_{i=1} \mathbf{x}_i \mathbf{x}_i' \right)^{-1} = \mathbb{E}[\mathbf{x}_i \mathbf{x}_i']^{-1}.$

- Juntando 1-4

$$\text{plim} \hat{\sigma}^2 = \text{plim} \frac{\hat{\mathbf{e}}' \hat{\mathbf{e}}}{N-K} = \sigma^2$$