

Econometría Avanzada

Estimadores de Matching y Reponderación

Manuel Fernández

10 de septiembre de 2025

Temas de la clase:

1. Independencia condicional
2. Propensity Score Matching (PSM)
 - Emparejamiento y propensity score
 - Soporte común
 - Algoritmos de emparejamiento
3. Modelo de regresión lineal
4. Inverse Probability Weighting (IPW)
5. Anexo

Independencia condicional

Selección en estudios observacionales

- Si la asignación al tratamiento $D_i \in \{0, 1\}$ **no es aleatoria**, el grupo de control puede no representar un contrafactual válido para los tratados:

$$\underbrace{\mathbb{E}[Y_i(0) \mid D_i = 1]}_{\text{Contrafactual}} \neq \underbrace{\mathbb{E}[Y_i(0) \mid D_i = 0]}_{\text{Estimable con el grupo de control}} .$$

Esto ocurre, por ejemplo, cuando las personas **se autoseleccionan** en el tratamiento.

- Suponga que la selección depende únicamente de factores **observables** $\mathbf{X}_i$, tal que:

$$Y_i(0), Y_i(1) \perp\!\!\!\perp D_i \mid \mathbf{X}_i.$$

Esta condición se conoce como **independencia condicional** o **ignorabilidad**: condicionar en $\mathbf{X}_i$ hace que la asignación sea “como si” fuera aleatoria.

Identificación del efecto causal bajo independencia condicional

- Defina el **efecto causal promedio condicional (CATE)**:

$$\tau(\mathbf{x}) \equiv \mathbb{E}[Y_i(1) - Y_i(0) \mid \mathbf{X}_i = \mathbf{x}].$$

Si se cumple la **independencia condicional**, la **diferencia de medias condicional** identifica el **CATE**:

$$\begin{aligned}\mathbb{E}[Y_i \mid \mathbf{X}_i, D_i = 1] - \mathbb{E}[Y_i \mid \mathbf{X}_i, D_i = 0] &= \mathbb{E}[Y_i(1) \mid \mathbf{X}_i, D_i = 1] - \mathbb{E}[Y_i(0) \mid \mathbf{X}_i, D_i = 0] \\ &= \mathbb{E}[Y_i(1) \mid \mathbf{X}_i] - \mathbb{E}[Y_i(0) \mid \mathbf{X}_i] \\ &= \tau(\mathbf{X}_i).\end{aligned}$$

- El efecto promedio en la población (**ATE** o **ATT**) es

$$\tau_{ATE} = \mathbb{E}[\tau(\mathbf{X}_i)] \quad \text{y} \quad \tau_{ATT} = \mathbb{E}[\tau(\mathbf{X}_i) \mid D_i = 1],$$

donde promediamos sobre la distribución de $\mathbf{X}_i$ en la población de interés.

Preguntas abiertas

1. ¿Cuándo es plausible suponer **independencia condicional**?
2. ¿Cómo estimar la diferencia de medias condicional y el **ATE** o **ATT**?

Propensity Score Matching (PSM)

Propensity Score Matching (PSM): Intuición

- Imagine una situación **hipotética** en la que, para cada unidad i tratada ($D_i = 1$), existiera un “**clon**” j : una unidad idéntica en todas las características *relevantes* (**observadas y no observadas**), pero que no recibe el tratamiento ($D_j = 0$).
- En ese caso, podríamos comparar los resultados de i y su **clon** j para estimar el efecto del tratamiento:

$$\tau_i = Y_i(1) - Y_i(0) \approx Y_i(1) - Y_j(0) = Y_i - Y_j.$$

Si i tuviera varios posibles **clones** (conjunto $\mathcal{C}(i)$), usaríamos el **promedio** de sus resultados como contrafactual:

$$\tau_i \approx Y_i - \mathbb{E}[Y_j | j \in \mathcal{C}(i)].$$

- Los métodos de **matching**, y **PSM** en particular, siguen esta intuición.

¿Cómo definir un clon en la práctica?

- Para cada unidad contamos con un conjunto de **características observables predeterminadas**, resumidas en el vector $\mathbf{X}_i$.
- La idea es **emparejar** cada tratado con una o varias unidades en el grupo de control que tengan valores similares de $\mathbf{X}_i$.
- **Dificultades en la práctica:**
 1. Sólo observamos un **conjunto limitado de covariables**: podemos emparejar en lo que está medido, pero no en factores no observados que también pueden influir.
 2. Es posible que no exista ninguna unidad en el grupo de control con los mismos valores exactos de $\mathbf{X}_i$.

Supuesto de independencia condicional

- El supuesto de **independencia condicional** establece que, una vez que emparejamos unidades de tratamiento y de control con el mismo vector de covariables $\mathbf{X}_i$, la asignación al tratamiento es **como si fuera aleatoria**.
- En este caso, el conjunto $\mathcal{C}(i)$ se define por los valores de $\mathbf{X}_i$ y permite aproximar el contrafactual no observado.

Implicaciones del supuesto

Este supuesto es **muy exigente**: requiere que **todos los factores** que influyen tanto en la probabilidad de recibir el tratamiento como en el resultado sean observables. $\Rightarrow$ No debe existir **sesgo de selección por variables no observadas**.

- Una solución natural es agrupar las unidades en la muestra en **celdas** según los valores de $\mathbf{X}_i$ y comparar tratados y controles dentro de cada celda.
- **Problema: maldición de la dimensionalidad**
 - Con k variables binarias hay 2^k posibles celdas.
 - Muchas celdas quedan con muy pocas (o ninguna) observaciones $\Rightarrow$ **estimaciones ruidosas**.
 - Algunas celdas pueden contener sólo tratados o sólo controles, impidiendo la comparación.

Emparejamiento por propensity score

- **Alternativa:** resumir el vector de covariables $\mathbf{X}_i$ en un **único escalar** y emparejar las unidades usando ese escalar y una **medida de distancia**.
- Ese escalar es el **propensity score**:

$$p_i \equiv \Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}].$$

Teorema del propensity score (Rosenbaum and Rubin, 1983)

$$Y_i(1), Y_i(0) \perp\!\!\!\perp D_i \mid \mathbf{X}_i \implies Y_i(1), Y_i(0) \perp\!\!\!\perp D_i \mid p_i.$$

Intuición: bajo **independencia condicional**, basta con condicionar en p_i en lugar de todo $\mathbf{X}_i$.

- Pregunta práctica: ¿cómo estimar p_i ?

Soporte común

- Para identificar efectos causales mediante *matching*, cada unidad tratada debe tener al menos un **control comparable**.
- En términos del **propensity score**, esto requiere que


$$0 < \Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}] < 1.$$

- Si $\Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}] = 1$: sólo hay tratados con esas características $\mathbf{x}$, sin controles comparables.
 - Si $\Pr[D_i = 1 \mid \mathbf{X}_i = \mathbf{x}] = 0$: sólo hay controles con esas características $\mathbf{x}$, sin tratados comparables.
 - En ambos casos, **no existe soporte común**.
- Cuando se cumplen simultáneamente el supuesto de **independencia condicional** y el de **soporte común**, hablamos de **ignorabilidad fuerte**.

Restricción al soporte común en la muestra

- Debemos restringir la muestra de estimación a la región de **soporte común** ($\mathcal{S}$):

$$\mathcal{S} = \left\{ p_i \in (0, 1) : \exists \text{ tratados y controles con ese } p_i \right\}.$$



- Implicación:** los efectos causales sólo son válidos para las unidades que pertenecen al **soporte común**.

Resumiendo: pasos para aplicar PSM

- El teorema del **propensity score** sugiere un procedimiento en cuatro pasos:
 1. **Estimar** el **propensity score** $\hat{p}_i$ para cada unidad (e.g., *logit*, *probit*).
 2. **Restringir** la muestra a la región de **soporte común**: $\{i: \hat{p}_i \in \mathcal{S}\}$.
 3. **Emparejar** tratados y controles con valores similares de $\hat{p}_i$.
 4. **Estimar** el efecto: comparar resultados entre unidades emparejadas y promediar para obtener el **efecto promedio del tratamiento**.

Algoritmos de emparejamiento: fórmula general

- **Estimando** (e.g., ATT en soporte común):

$$\begin{aligned}\tau_{ATT} &= \mathbb{E} \left[\mathbb{E}[Y_i \mid D_i = 1, p_i] - \mathbb{E}[Y_i \mid D_i = 0, p_i] \mid D_i = 1, p_i \in \mathcal{S} \right] \\ &= \mathbb{E} \left[\tau(p_i) \mid D_i = 1, p_i \in \mathcal{S} \right] \quad \text{donde} \quad p_i \equiv \Pr[D_i = 1 \mid \mathbf{X}_i].\end{aligned}$$

- **Estimador**: con una muestra de N_1 tratados en el soporte común,

$$\hat{\tau}_{ATT} = \frac{1}{N_1} \sum_{\{i: D_i=1, \hat{p}_i \in \mathcal{S}\}} \left(Y_i - \sum_{\{j: D_j=0, \hat{p}_j \in \mathcal{S}\}} \omega(i, j) Y_j \right).$$

donde:

- $\hat{p}_i$: propensity score estimado.
- $\mathcal{S}$: región de soporte común.
- $\omega(i, j)$: peso asignado al control j al construir el contrafactual de la unidad tratada i , con $\sum_{\{j: D_j=0, \hat{p}_j \in \mathcal{S}\}} \omega(i, j) = 1$ para cada i .

Algoritmos de emparejamiento: Vecino más cercano

- Cada unidad tratada i se empareja con la unidad de control j cuyo **propensity score estimado** sea el más cercano al de i

$$\omega(i, j) = \mathbf{1}\{j : |\hat{p}_i - \hat{p}_j| = \min_{\{k: D_k=0, \hat{p}_k \in \mathcal{S}\}} |\hat{p}_i - \hat{p}_k|\}$$

En este caso, $\omega(i, j)$ toma el valor de uno para el vecino más cercano y cero de lo contrario.

- En la práctica, nada garantiza que el **vecino más cercano** sea efectivamente “cercano”. Es fundamental verificar el **balance** en las covariables $\mathbf{X}$'s entre los grupos de tratamiento y control después del emparejamiento.

Vecino más cercano: Algunas consideraciones

1. **Con reemplazo:** varias unidades tratadas pueden ser emparejadas a la misma unidad en el grupo de control.
2. **Sin reemplazo:** si la unidad en el grupo de control fue emparejada, no se usa más $\implies$ El orden del emparejamiento importa!
 - Una extensión natural es usar los M **vecinos más cercanos**, asignando un peso respectivo $\frac{1}{M}$ a cada uno.

Algoritmos de emparejamiento: Distancia máxima

- **Distancia máxima (radio):** cada unidad tratada i se empareja con las unidades de control cuyo **propensity score** esté a una distancia máxima q . Definimos

$$L(i, j) = \mathbf{1}\{j : |\hat{p}_i - \hat{p}_j| \leq q\},$$

y asignamos el peso

$$\omega(i, j) = \begin{cases} \frac{1}{\sum_{\{j: D_j=0, \hat{p}_j \in S\}} L(i, j)} & \text{si } L(i, j) = 1 \\ 0 & \text{si } L(i, j) = 0 \end{cases}$$

- En distancia máxima versión **caliper**, se usan únicamente con los M vecinos más cercanos, condicional en estar a una distancia máxima q .

Algoritmos de emparejamiento: Kernel

- **Emparejamiento usando función de Kernel:** Asigna mayor peso a las unidades de control más **cercanas** y menor peso a las más **lejanas**, según la distancia en el **propensity score estimado**.
- El contrafactual predicho para cada unidad i es:


$$\hat{Y}_i(0) = \frac{\sum_{\{j: D_j=0, \hat{p}_j \in \mathcal{S}\}} K\left(\frac{\hat{p}_i - \hat{p}_j}{h}\right) Y_j}{\sum_{\{j: D_j=0, \hat{p}_j \in \mathcal{S}\}} K\left(\frac{\hat{p}_i - \hat{p}_j}{h}\right)}$$

donde $K(\cdot)$ es la **función Kernel** y h es el **ancho de banda**.

- **Estimador:**

$$\hat{\tau}_{ATT} = \frac{1}{N_1} \sum_{\{i: D_i=1, \hat{p}_i \in \mathcal{S}\}} \left(Y_i - \hat{Y}_i(0) \right),$$

Funciones de Kernel



Por ejemplo, si el Kernel es **Gaussiano**, los pesos decrecen siguiendo la distribución normal.

Errores estándar en PSM

- En PSM, los errores estándar deben reflejar tres fuentes de variación:
 - 1) **Estimación** del propensity score $\hat{p}_i$.
 - 2) **Restricción** al soporte común.
 - 3) **Algoritmo** de emparejamiento.

El uso de **bootstrapping** (Efron, 1979) es frecuente, pero **puede ser inconsistente** (Abadie and Imbens, 2008).

- **Alternativas:**
 - Usar fórmulas **analíticas de varianza** para matching (Abadie and Imbens, 2006, 2016).
 - En métodos “suaves” (kernel, radio): estimar varianzas con bootstrap, **re-estimando** $\hat{p}_i$ y rehaciendo *trimming* en cada réplica.

Modelo de regresión lineal

Aproximación a la CEF

- Suponga que, en ausencia de tratamiento, **modelamos**

$$\mathbb{E}[Y_i(0)|\mathbf{X}_i] = \mathbf{X}_i'\beta.$$

Es una aproximación (proyección lineal), no sabemos la CEF “real”:

- Imponemos una forma funcional que nos puede llevar a **errores de especificación**.
 - Si los soportes de $\mathbf{X}$ difieren entre tratados y controles, $\mathbf{X}_i'\beta$ puede **extrapolar**.
- Bajo **independencia condicional** $Y_i(0), Y_i(1) \perp D_i \mid \mathbf{X}_i$:
$$Y_i = Y_i(0) + \left(Y_i(1) - Y_i(0) \right) D_i \implies \mathbb{E}[Y_i|\mathbf{X}_i, D_i] = \tau(\mathbf{X}_i)D_i + \mathbb{E}[Y_i(0)|\mathbf{X}_i, D_i]$$
$$\approx \tau(\mathbf{X}_i)D_i + \mathbf{X}_i'\beta.$$
donde $\tau(\mathbf{X}_i) \equiv \mathbb{E}[Y_i(1) - Y_i(0)|\mathbf{X}_i]$ son los **CATE**.

El modelo de regresión lineal

- Considere el modelo de regresión:

$$Y_i = \tau D_i + \mathbf{X}_i' \beta + e_i. \quad (1)$$

¿Cómo se relaciona $\mathbb{E}[\tau(\mathbf{X}_i)]$ y τ ? ¿Qué está estimando MCO?

- Por el teorema de **Frisch–Waugh–Lovell** (FWL), estimar (1) por MCO es equivalente a estimar

$$\tilde{Y}_i = \tau \tilde{D}_i + \eta_i,$$

donde $\tilde{Y}_i$ y $\tilde{D}_i$ son los **residuales de la proyección lineal** de Y_i y D_i en $\mathbf{X}_i$, respectivamente.

¿Qué estima MCO en el modelo de regresión lineal?

- Se puede demostrar que:

$$\text{plim } \hat{\tau}_{\text{mco}} = \frac{\mathbb{E} [\tau(\mathbf{X}_i) \omega(\mathbf{X}_i)]}{\mathbb{E} [\omega(\mathbf{X}_i)]} \neq \mathbb{E} [\tau(\mathbf{X}_i)]$$

donde $\omega(\mathbf{X}_i) \equiv \mathbb{E} [\tilde{D}_i^2 \mid \mathbf{X}_i] \geq 0$.

- En palabras, el estimador de MCO da un promedio ponderado de los **CATE**, donde los pesos son proporcionales a la varianza condicional del tratamiento $\implies$ MCO actúa como un estimador de *matching* con una estructura de pesos específica.
- Si los efectos son **homogéneos**: $\tau(\mathbf{X}_i) = \tau \forall \mathbf{X}_i$, se cumple que $\text{plim } \hat{\tau}_{\text{mco}} = \mathbb{E} [\tau(\mathbf{X}_i)] = \tau$. De lo contrario, el efecto estimado puede diferir de los obtenidos con estimadores de *matching*.

Extrapolación si la CEF no es lineal

- **Error de especificación:** los pesos implícitos de MCO fijan la **importancia relativa** de cada región del soporte de $\mathbf{X}$, pero **no corrigen** el sesgo si la CEF verdadera no es lineal.
- **Problema de extrapolación:** con **pobre overlap** entre tratados y controles, el contrafactual de algunos tratados se construye usando observaciones “lejanas” en el espacio de covariables.
- **Consecuencia:** aun con muestras grandes, $\hat{\tau}_{mco}$ puede ser **inconsistente** si la CEF es no lineal y/o existe poco *overlap*.

Angrist and Pischke (2011)

"We believe regression should be the starting point for most empirical projects. This is not a theorem; undoubtedly, there are circumstances where propensity score matching provides more reliable estimates of average causal effects. The first reason we don't find ourselves on the propensity-score bandwagon is practical: there are many details to be filled in when implementing propensity-score matching – such as how to model the score and how to do inference – these details are not yet standardized. Different researchers might therefore reach very different conclusions, even when using the same data and covariates."

Imbens (2015)

“Researchers continue to use ordinary linear regression methods with an indicator for the treatment and covariates entering additively and linearly. However, such simple methods do not always work well... the simple ordinary least squares estimator, which ultimately relies on the same fundamental unconfoundedness assumption as matching and propensity score estimators, but combines that assumption with strong functional form restrictions, is likely to be inadequate for estimating average treatment effects.”

Inverse Probability Weighting (IPW)

Inverse Probability Weighting (IPW)

- Suponga que se cumple **ignorabilidad fuerte**:

$$Y_i(1), Y_i(0) \perp D_i \mid \mathbf{X}_i, \quad p_i \equiv \Pr(D_i = 1 \mid \mathbf{X}_i) \in (0, 1),$$

entonces se cumple la siguiente **identidad** (Horvitz and Thompson, 1952):

$$\mathbb{E} \left[\frac{D_i Y_i}{p_i} \right] = \mathbb{E}[Y_i(1)], \quad \mathbb{E} \left[\frac{(1 - D_i) Y_i}{1 - p_i} \right] = \mathbb{E}[Y_i(0)]$$

◀ Demostración

En consecuencia,

$$\tau_{ATE} = \mathbb{E} \left[\frac{D_i Y_i}{p_i} - \frac{(1 - D_i) Y_i}{1 - p_i} \right].$$

- Esto motiva el **estimador IPW** en la práctica:

$$\hat{\tau}_{IPW} = \frac{1}{N} \sum_i \left(\frac{D_i Y_i}{\hat{p}_i} - \frac{(1 - D_i) Y_i}{1 - \hat{p}_i} \right)$$

IPW normalizado (Hájek)

- El estimador IPW de Horvitz and Thompson (1952) puede tener alta varianza porque los pesos

$$\omega_i(1) = \frac{D_i}{\hat{p}_i}, \quad \omega_i(0) = \frac{1 - D_i}{1 - \hat{p}_i},$$

no necesariamente suman a 1 en la muestra.

- IPW de Hájek (normalizado): reescala los pesos dentro de cada grupo,

$$\hat{\tau}_{\text{IPW}}^H = \frac{\sum_i \frac{D_i Y_i}{\hat{p}_i}}{\sum_i \frac{D_i}{\hat{p}_i}} - \frac{\sum_i \frac{(1-D_i) Y_i}{1-\hat{p}_i}}{\sum_i \frac{(1-D_i)}{1-\hat{p}_i}}.$$

donde $\sum_i \frac{D_i}{\hat{p}_i} \xrightarrow{P} N$, y $\sum_i \frac{1-D_i}{1-\hat{p}_i} \xrightarrow{P} N$. Este estimador es **consistente** y suele tener menor varianza. También hace que el estimador se interprete como una media ponderada usual.

IPW: intuición no técnica


- Si tratados y controles difieren en sus covariables $\mathbf{X}$, un *promedio directo* compara **manzanas con peras**.
- El **IPW repondera** las observaciones según su *propensity score*:
 - Más peso a las unidades **raras** (con baja probabilidad de estar en su grupo).
 - Menos peso a las unidades **comunes**.

De esta forma, la muestra ponderada genera **overlap artificial**:
tratados y controles terminan con distribuciones comparables de $\mathbf{X}$.


- El promedio ponderado elimina el sesgo de composición y aproxima el **efecto causal promedio**.

Overlap del propensity score: con y sin ajuste

(a) Sin ajuste



(b) Con ajuste por IPW



Nota: Con ajuste, la densidad del propensity score se calcula ponderando cada observación por su peso IPW.

- **Sin ajuste:** las distribuciones de los grupos tratados y de control en el propensity score son muy distintas.
- **Con IPW:** al ponderar, las distribuciones se hacen comparables

Anexo

Demostración breve (I)

- Consideremos la identidad para $Y_i(1)$ (el caso $Y_i(0)$ es análogo).
- Recordemos que $D_i \in \{0, 1\}$ y $Y_i = (1 - D_i)Y_i(0) + D_iY_i(1)$.
Sustituyendo en $\frac{D_i Y_i}{p_i}$:

$$\frac{D_i Y_i}{p_i} = \frac{D_i(1 - D_i)Y_i(0)}{p_i} + \frac{D_i^2 Y_i(1)}{p_i}.$$

Como $D_i(1 - D_i) = 0$ y $D_i^2 = D_i$:

$$\frac{D_i Y_i}{p_i} = \frac{D_i Y_i(1)}{p_i}.$$

- Tomamos la esperanza condicional dado $\mathbf{X}_i$:

$$\begin{aligned}\mathbb{E}\left[\frac{D_i Y_i}{p_i} \mid \mathbf{X}_i\right] &= \frac{1}{p_i} \mathbb{E}[D_i Y_i(1) \mid \mathbf{X}_i] \\ &= \frac{1}{p_i} \mathbb{E}[D_i \mathbb{E}[Y_i(1) \mid \mathbf{X}_i, D_i] \mid \mathbf{X}_i] \quad (\text{LEI}).\end{aligned}$$

Demostración breve (II)

- Por **ignorabilidad**, $Y_i(1) \perp D_i \mid \mathbf{X}_i$, de modo que

$$\mathbb{E}[Y_i(1) \mid \mathbf{X}_i, D_i] = \mathbb{E}[Y_i(1) \mid \mathbf{X}_i].$$

Así,

$$\mathbb{E}\left[\frac{D_i Y_i}{p_i} \mid \mathbf{X}_i\right] = \frac{1}{p_i} \mathbb{E}[Y_i(1) \mid \mathbf{X}_i] \mathbb{E}[D_i \mid \mathbf{X}_i].$$

Como $\mathbb{E}[D_i \mid \mathbf{X}_i] = p_i$, obtenemos:

$$\mathbb{E}\left[\frac{D_i Y_i}{p_i} \mid \mathbf{X}_i\right] = \mathbb{E}[Y_i(1) \mid \mathbf{X}_i].$$

- Finalmente, por la **ley de expectativas iteradas**:

$$\mathbb{E}\left[\frac{D_i Y_i}{p_i}\right] = \mathbb{E}[\mathbb{E}[Y_i(1) \mid \mathbf{X}_i]] = \mathbb{E}[Y_i(1)].$$